

Generación simbólica de música desde texto con arquitectura encoder-decoder

Proyecto final: Procesamiento de datos
secuenciales con Deep Learning

Saulo Quiñones Góngora - 22506635
Adrian Felipe Vargas Rojas - 22505561
Miguel Angel Franco Restrepo - 22506163





Contexto

A pesar que desde hace unos 4 años nos encontramos en una etapa de explosión de modelos generativos, el campo de creación de música en su formato más rico y versátil (MIDI) no ha sido abordado

¿POSIBLES CAUSAS?

- Ausencia de datasets a gran escala que relacionen archivos MIDI con descripciones textuales ricas

Motivación

- La creación de música ha sido restringida unicamente a ese grupo de personas con conocimiento técnico en teoría musical
- El MIDI es una “partitura digital”, esto quiere decir que los productores y cualquier interesado puede modificarla y adaptarla

La motivación central de este proyecto radica en explorar y comprender cómo una arquitectura encoder-decoder, apoyada en modelos de lenguaje pre-entrenados como FLAN-T5 y en representaciones simbólicas de música como REMI+, puede cerrar la brecha entre la intención textual del usuario y la generación musical simbólica.



Objetivo


Desarrollar el primer modelo end-to-end que permita la generación de archivos MIDI a partir de descripciones textuales brindadas por usuarios técnicos y no técnicos, haciendo uso de un encoder pre-entrenado que codifica las descripciones textuales y un decoder Transformer autoregresivo para generar las correspondientes secuencias MIDI, mediante una estrategia de entrenamiento semi-supervisado sobre el dataset SymphonyNet y fine-tuning sobre MidiCaps



TEXT2MIDI ARCHITECTURE


Text2midi: Generating Symbolic Music from Captions

<https://github.com/AMAIL-Lab/Text2midi>




Encoder

ENCODER — FLAN-T5 base




DECODER






Decoder

Tokenización MIDI con REMI+




Notación musical



REMI+

Fuente: Fradet (2024)

El decoder no puede leer MIDI binario. REMI+ convierte eventos musicales en índices discretos, al igual que palabras. El tamaño del vocabulario es de 524 tokens



Input Embedding

Vector resultante

Token de inicio

<BOS>
idx = 1



Búsqueda de
fila

fila 1 - <BOS> [0.67, 0.31, -0.45 ...]

fila 2 - Bar [0.12, -0.88, 0.34 ...]

fila 3 - Tempo [0.55, 0.02, -0.71 ...]

524 filas en total

0.61

0.31

-0.45

...

0.09

<BOS>

Bar

Tempo 116


Pos. 0

Pitch 60

<EOS>


Vanilla Positional Encoding → Paso al Masked Self Attention

ENCODER



Decoder y salida —
Generación token
a token

Metodología



Uso de pesos

- Se detecta el dispositivo de computo disponible
- Se descargan los artefactos de HuggingFace una única vez (Se guarda en la caché local)
- Con REMI+ se obtiene la representación de eventos musicales como notas, tiempos, instrumentos y dinámicas
- Inicialización de la arquitectura decoder
- Se inicializa el tokenizador de texto de FLAN T5 que será encargado de procesar las descripciones textuales del usuario

Inferencia


- Una vez se cuenta con los tokens se generan los tensores que representan el texto como secuencias numéricas
- Una vez el decoder cuenta con estos tensores comienza la generación autoregresiva de tokens
- Cross-Attention permite que el token MIDI actual consulte los Hidden states que genera el encoder
- Masked-self-Attention garantiza que el decoder solo tenga visibilidad de los tokens musicales presentes y ya generados
- Configuración de la temperatura, la cual determina el nivel de aleatoriedad que tiene cada una de las predicciones del transformer
- Selección de la longitud del archivo MIDI que se generará
- Se destokeniza la secuencia de tokens, construyendo notas, velocidades y demás atributos



Innovaciones del modelo



- Primer modelo end-to-end texto → MIDI.
 - Encoder FLAN-T5 Congelado (113M de parámetros).
 - Preentrenamiento semi-supervisado SymphonyNet + pseudo-captions.
 - Flash Attention para mayor eficiencia computacional y de memoria.
 - Sentence omission como regularización
- 



Aspectos a mejorar



- Ampliar ventana de contexto a 4096 tokens (~10 min de música)
 - Control de duración explícito en segundos o compases
 - Fine-tuning del encoder FLAN-T5 en dominio musical
 - Generación condicionada por segmentos para evitar incoherencia inicial
 - Interpretación de referencias culturales y estilísticas en el caption
- 




RESULTADOS Y ANÁLISIS

Métrica	text2midi	MuseCoco
Compression Ratio	2.31	2.12
CLAP Score	0.22	0.21
Tempo Bin (%)	39.70	21.71
Correct Key (%)	33.60	13.70



Criterio	MidiCaps GT	text2midi	MuseCoco
Calidad musical	5.79	4.62	4.40
Match general	5.42	4.67	4.07
Match género	5.54	4.98	4.40
Match mood	5.70	5.00	4.32
Match tonalidad	4.61	3.64	3.36
Match acordes	3.20	2.50	2.00
Match tempo	5.89	5.42	4.94






RESULTADOS Y ANÁLISIS



Pruebas propias

- Música coherente con el caption a partir de los primeros 5-10 segundos ✓
- Generación con max_len=1000: ~38.5s en RTX 5070 Ti (paper: ~55s con 2000) ✓
- Temperatura 1.0 → resultados coherentes Temperatura > 1.2 → degradación notable ✓
- Instrumentos principales respetados Instrumentos secundarios: omitidos ✗
- "flute music 15 seconds" → MIDI de ~20s Sin control de duración explícito ✗
- Primeros segundos menos coherentes con el caption → se estabiliza progresivamente ✗
- Interfaz Streamlit, reproductor waterfall, descarga MIDI y MP3 funcionaron correctamente ✓



CONCLUSIONES

Aprendizajes

- El encoder congelado es una estrategia efectiva para aprovechar modelos preentrenados sin costos computacionales adicionales.
- Flash Attention permite procesar secuencias largas de forma eficiente.
- REMI+ convierte la generación musical en un problema análogo al de generación de texto, permitiendo aplicar directamente arquitecturas de LLMs.
- Sentence omission mejora la robustez del modelo ante captions incompletos del mundo real.

Limitaciones identificadas

- El modelo ignora con frecuencia instrumentos secundarios del caption.
- Tempo y acordes son difíciles de controlar con precisión, REMI+ no incluye tokens de acorde explícitos, estos emergen implícitamente de la co-ocurrencia de tokens de pitch.
- No interpreta instrucciones de duración temporal, la longitud depende exclusivamente de max_len.
- El rango de temperatura útil es estrecho, valores superiores a 1.0 degradan la coherencia musical.
- Los primeros segundos del MIDI tienden a ser menos coherentes con el caption, estabilizándose progresivamente.





REFERENCIAS

FlashAttention: Fast and Memory-Efficient Exact Attention with IO-Awareness

- T. Dao, D. Y. Fu, S. Ermon, A. Rudra, and C. Re, "FlashAttention: Fast and Memory-Efficient Exact Attention with IO-Awareness," in Advances in Neural Information Processing Systems (NeurIPS), 2022. [Online]. Available: <https://arxiv.org/abs/2205.14135>

Text2midi: Generating Symbolic Music from Captions

- K. Bhandari, A. Roy, K. Wang, G. Puri, S. Colton, and D. Herremans, "Text2midi: Generating Symbolic Music from Captions," arXiv:2412.16526, 2024. [Online]. Available: <https://arxiv.org/abs/2412.16526>

Attention Is All You Need

- A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, "Attention Is All You Need," in Advances in Neural Information Processing Systems (NeurIPS), vol. 30, 2017. [Online]. Available: <https://arxiv.org/abs/1706.03762>

Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer

- C. Raffel, N. Shazeer, A. Roberts, K. Lee, S. Narang, M. Matena, Y. Zhou, W. Li, and P. J. Liu, "Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer," Journal of Machine Learning Research, vol. 21, no. 140, pp. 1–67, 2020. [Online]. Available: <https://arxiv.org/abs/1910.10683>

Scaling Instruction-Finetuned Language Models

- H. W. Chung, L. Hou, S. Longpre, B. Zoph, Y. Tay, W. Fedus, et al., "Scaling Instruction-Finetuned Language Models," Journal of Machine Learning Research, vol. 25, no. 70, pp. 1–53, 2024. [Online]. Available: <https://arxiv.org/abs/2210.11416>





REFERENCIAS

Pop Music Transformer: Beat-based Modeling and Generation of Expressive Pop Piano Compositions

- Y.-S. Huang and Y.-H. Yang, "Pop Music Transformer: Beat-based Modeling and Generation of Expressive Pop Piano Compositions," in Proceedings of the 28th ACM International Conference on Multimedia (MM), 2020. [Online]. Available: <https://arxiv.org/abs/2002.00212>

FIGARO: Controllable Music Generation using Learned and Expert Features," in The Eleventh International Conference on Learning Representations

- D. von Rutte, L. Biggio, Y. Kilcher, and T. Hofmann, "FIGARO: Controllable Music Generation using Learned and Expert Features," in The Eleventh International Conference on Learning Representations (ICLR), 2023. [Online]. Available: <https://arxiv.org/abs/2201.10936>

Gaussian Error Linear Units

- D. Hendrycks and K. Gimpel, "Gaussian Error Linear Units (GELUs)," arXiv:1606.08415, 2016. [Online]. Available: <https://arxiv.org/abs/1606.08415>

google/flan-t5-base

- Google, "FLAN-T5 Base Model Card and Configuration," HuggingFace Hub, 2023. [Online]. Available: <https://huggingface.co/google/flan-t5-base/blob/main/config.json>

Tokenizations

- N. Fradet, J.-P. Briot, F. Chhel, A. El Fallah Seghrouchni, and N. Gutowski, "MidiTok: A Python Package for MIDI File Tokenization," in Extended Abstracts for the Late-Breaking Demo Session of the 22nd ISMIR Conference, 2021. [Online]. Available: <https://miditok.readthedocs.io/en/v3.0.1/tokenizations.html>

